Résumé de l'algorithme de traitement du signal du brevet

PERRET Loris
BONNEAU Baptiste

CLERMONT AUVERGNE INP Isima

Le brevet étudié et résumé ci-dessous est le brevet américain US 7,627,477,B2, intitulé *Robust and Invariant Audio Pattern Matching* et qui a été délivré à la société Landmark Digital Services, le 1er décembre 2009. Ce brevet protège les recherches d'Avery Li-Chun Wang et Daniel Culbert sur les technologies audio avancées. Le brevet a été rédigé par le cabinet Woodcock Washburn LLP, et a été examiné par le Bureau américain des brevets et des marques (USPTO).

Ce brevet fait partie du domaine du traitement audio qui a pour objectif la reconnaissance rapide et précise de motifs dans des bases de données de fichiers audio. Cette problématique est d'autant plus importante lorsque les signaux audio peuvent varier en termes de qualité, de vitesse de lecture ou d'environnement d'enregistrement.

L'innovation présentée vise à résoudre deux principaux problèmes rencontrés par les technologies actuelles. Premièrement, ces technologies rencontrent des difficultés à s'adapter aux variations de vitesse de lecture des fichiers audio. Une variation dans un fichier audio. Une variation dans un fichier audio désigne tout changement dans les caractéristiques sonores du fichier, telles que l'intensité, la fréquence, la tonalité ou le timbre. Ces variations, qu'elles soient intentionnelles ou accidentelles modifient les caractéristiques des signaux ce qui rend leur analyse et leur comparaison plus complexes. Par exemple, un fichier audio joué à une vitesse différente de l'original peut être mal identifié par les systèmes existants, ce qui peut erroner la précision des résultats.

Ensuite, le brevet évoque le problème des bruits parasites qui réduisent souvent la qualité des enregistrements audio. Le terme "bruit" fait référence à tout son indésirable ou étranger qui se superpose à l'audio. Ces bruits peuvent inclure des interférences de fond, comme des conversations, le son du vent, etc. Ces perturbations posent problème car elles compliquent l'extraction des caractéristiques nécessaires à la reconnaissance des différents motifs.

L'objectif de ces recherches est de proposer une solution efficace, robuste et invariante permettant de comparer deux échantillons audio en s'adaptant aux différentes variations. Cela permet divers usages tels que la recherche musicale ou encore la détection sonore dans des contextes bruyants.

L'objectif de cette méthode est de fournir une reconnaissance rapide et précise des motifs audio en utilisant des empreintes. La partie suivante détaille les processus et les techniques utilisées. La méthode se décompose en cinq grandes étapes.

1. Extraction des empreintes digitales audio

Pour extraire les empreintes digitales audio, il faut commencer par réaliser un spectrogramme qui représente graphiquement le spectre fréquentiel de notre signal qui évolue au cours du temps. Il est construit à partir d'un ensemble de transformée de Fourier appliqué à des échantillons successifs du signal audio. La transformée de Fourier pour un échantillon $w(t)$ centré sur un temps t_0 est donnée par :

$$X(f,t0) = \int_{-\infty}^{+\infty} x(t)\, w(t - t_0)\, e^{-j2\pi f t}\, dt$$

$$x(t)\colon signal \quad f\colon fréquence \quad w(t)\colon échantillon \quad t\colon temps$$

La transformée de Fourier est une fonction qui permet d'extraire les fréquences d'un signal qui n'est pas périodique.

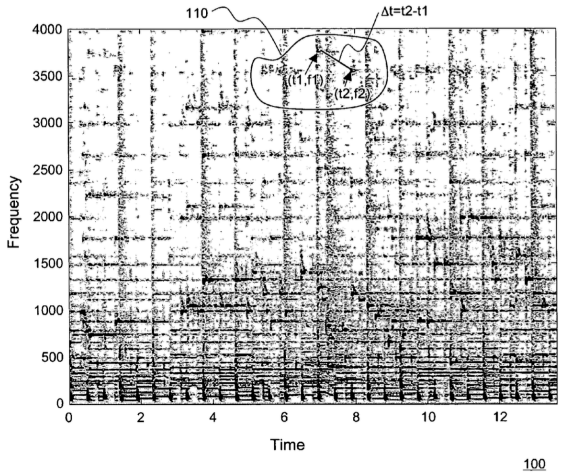
Le spectrogramme $S(f,t)$ est donné par la magnitude au carré de $X(f,t_0)$:

$$S(f,t) = |X(f,t)|^2$$

Chaque valeur $S(f,t)$ représente l'intensité du signal à une fréquence f à un moment donné t.

Dans notre cas, nous avons une fréquence d'échantillonnage de $8\,kHz$, une taille d'échantillon $K = 512\,points$, pour être plus efficace, les échantillons doivent se chevaucher.

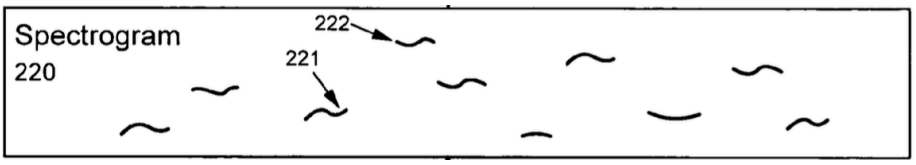
Voici un exemple de spectrogramme qui pourrait être généré :



L'étape suivante consiste en l'identification des pics locaux dans le spectrogramme. Ces pics sont représentés par des points dans le spectrogramme et indiquent l'intensité maximale atteinte dans un intervalle donné (21×21 dans notre cas). Pour les identifier, il faut comparer la valeur de l'intensité S d'un point (f, t) à celle de ses voisins dans l'intervalle :

$$S(f_i, t_i) > S(f_j, t_j) \qquad \forall\, (f_j, t_j) \in voisinage\,(f_i, t_i) \qquad f\colon fréquence \qquad t\colon temps$$

Par la suite, ces pics permettront d'identifier des caractéristiques importantes du signal permettant de comparer les différents échantillons.



Sur ce diagramme, nous pouvons apercevoir plusieurs pics (exemple : 221, 222).
Si nous avions un signal sans variation avec une fréquence constante de 100 Hz par exemple, nous aurions un pic à la même fréquence tout au long du spectrogramme

Enfin, il faut construire des objets d'empreintes qui vont contenir chacun des pics qui seront détectés. Chaque objet sera constitué d'une localisation avec les coordonnées temporelles t_i et fréquentielles f_i. Il y aura aussi une composante invariante. Cela pourrait être par exemple le ratio entre deux fréquences proches calculé grâce à :

$$Invariant(O_i, O_j) = \frac{f_j}{f_i}$$

La dernière propriété de cet objet sera une composante variante qui est la fréquence absolue f_i, qui peut être affectée par des déformations.

2. Correspondance entre empreintes

Afin de vérifier que deux échantillons soient similaires, nous devons comparer leur empreinte dans le but de vérifier s'il y a une correspondance. Pour cela, nous devons analyser les caractéristiques invariantes de leurs objets d'empreinte et établir des correspondances entre eux, en fonction de ces critères.
Pour chaque paire d'empreintes (O_{A_i}, O_{B_j}), une correspondance est validée si :

$$\left| \frac{f_{B_j}}{f_{A_i}} - 1 \right| < \epsilon \qquad \epsilon : marge\ d'erreur$$

La marge d'erreur est déterminée en fonction de la résolution fréquentielle du spectrogramme.

Une fois une correspondance trouvée, nous devons calculer la valeur relative. Cette valeur est utilisée pour décrire la relation entre les objets. Par exemple, pour une fréquence absolue :

$$Valeur\ relative\ = \frac{f_{B_j}}{f_{A_i}}$$

Si nous prenons l'exemple de deux échantillons où un signal est joué à une vitesse 1,2 fois supérieure que l'autre, les valeurs relatives seront centrées autour de 1,2. De même, avec un échantillon qui a une fréquence de 100 Hz et l'autre de 200, nous aurons des valeurs relatives autour de 2, etc.

Pour analyser les correspondances entre deux échantillons, nous utiliserons un histogramme. Dans cet histogramme, chaque barre correspondra à un intervalle spécifique de valeurs relatives. Cet histogramme est obtenu avec :

$$H(R) = \sum_{k=1}^{N} \delta(R - R_k)$$

δ: $fonction\ indicatrice$ $\quad$ R_k: $valeurs\ relatives$

N: $nombre\ total\ de\ paires\ correspondantes$

Un pic dans l'histogramme indique une forte correspondance avec une relation commune entre les échantillons.

3. Paramètres globaux

Pour chaque pic détecté, nous devons calculer des paramètres globaux comme la vitesse relative R_s et le décalage Δt. Ces paramètres globaux servent à affiner l'alignement général entre deux échantillons. La valeur relative qui peut paraître similaire est utilisée pour mesurer des différences locales à un instant t, les paramètres globaux calculent les différences sur l'ensemble des échantillons.

La vitesse relative R_s est calculée comme une moyenne pondérée des valeurs relatives, elle estime la vitesse globale d'un échantillon par rapport à l'autre.

$$R_s = \frac{\Sigma_{R \in voisinage} R.H(R)}{\Sigma_{R \in voisinage} H(R)} \qquad H\colon\ histogramme\ des\ valeurs\ relatives$$

Le décalage temporel Δt permet de compenser le décalage entre les échantillons après avoir estimé la vitesse relative.

$$\Delta t = t_{B_j} - R_s . t_{A_i}$$

Similairement aux valeurs relatives, si un échantillon est joué 10 % plus vite que l'original, $R_s = 1,1$. Nous devrons ensuite ajuster le décalage pour compenser l'augmentation.

5. Détection des déformations non linéaires

Lorsque les relations linéaires ne suffisent pas, nous pouvons utiliser des techniques de régression robuste. Par exemple, nous pouvons analyser un scatterplot des correspondances temporelles pour détecter des motifs non linéaires.

Les déformations non linéaires peuvent être des variations de vitesse de lecture par exemple. Ces déformations affectent les caractéristiques des signaux audio de manière non proportionnelle qui compliquent la correspondance directe entre deux échantillons.

Lorsqu'une déformation est détectée dans un histogramme, il faut appliquer une technique de compensation en ajustant les temps et fréquences localement grâce à une analyse locale autour des pics détectés.

Ces techniques permettent de synchroniser deux enregistrements même s'ils ont subi des modifications non linéaires. Elles sont robustes contre les bruits et les erreurs dues à ces transformations complexes.